



UNIVERSIDAD
NACIONAL
DE LA PLATA

Minería de Datos y Aprendizaje Automático

Clase 3
Árboles de decisión

2026

Temario

1

Árboles de decisión

2

Métricas de desorden

3

Visualización de un árbol de decisión

4

Predicción de un árbol de decisión AD

5

Métricas de evaluación

01

Árboles de decisión




Árbol de decisión

- Es un modelo de predicción muy utilizado en Minería de Datos.
- Por su forma jerárquica, permite visualizar la organización de los atributos.
- Se construye a partir de la identificación sucesiva de los atributos más relevantes.




Árbol de decisión



Los árboles se encargan de particionar el espacio de las muestras de manera recursiva.


Espacio de las muestras



¿Cómo podemos describir a cada grupo de deportistas en función del peso y la altura?

Deportista	Peso	Altura	Deporte
1	73	171	Fútbol
2	91	172	Fútbol
3	100	178	Fútbol
4	89	181	Fútbol
5	73	164	Fútbol
6	95	166	Fútbol
7	88	178	Fútbol
8	99	171	Fútbol
9	57	166	Fútbol
10	60	161	Fútbol
11	50	169	Fútbol
12	101	162	Fútbol
13	64	168	Fútbol
14	87	168	Fútbol
15	50	163	Fútbol
16	56	163	Fútbol
17	82	174	Fútbol
18	91	205	Rugby
19	92	203	Rugby
20	96	205	Rugby
21	91	199	Rugby
22	96	199	Rugby
23	93	196	Rugby
24	98	197	Rugby
25	100	201	Rugby
26	65	176	Voley
27	57	180	Voley
28	51	174	Voley
29	69	190	Voley
30	58	173	Voley
31	71	181	Voley
32	60	182	Voley
33	71	176	Voley
34	64	189	Voley
35	59	185	Voley
36	66	183	Voley
37	75	173	Voley
38	65	185	Voley
39	70	184	Voley

Árbol resultante



Conocimiento extraído del árbol

Las reglas tienen la forma → **Si** [Antecedente] **entonces** [Consecuente]

El antecedente tiene una o más condiciones, siempre haciendo referencia a algún atributo del dataset.

El consecuente suele ser una etiqueta, categoría o clase.

Las reglas son descriptivas y entendibles por los humanos.

Si altura > 193 entonces Juega al rugby

Si altura < 193 y peso > 79 entonces Juega al fútbol

Si altura < 172 y peso < 79 entonces Juega al fútbol

Si $172 < \text{altura} < 193$ y peso < 79 entonces Juega al voley

Árbol de decisión – Aplicaciones

Modelo descriptivo

- Su estructura jerárquica les permite mostrar cómo está organizada la información disponible.

Modelo predictivo

- Recorriendo sus ramas se obtienen reglas que permiten tomar decisiones.
- Si todas las hojas se refieren al mismo atributo y es discreto es un árbol de clasificación.





Algoritmos para la obtención de árboles

CART (1984) - Classification and Regression Trees

Leo Breiman, Jerome Friedman, Richard Olshen y Charles Stone

ID3 (1986) - Iterative Dichotomiser 3

J. Ross Quinlan

C4.5 (1993) y C5.0 (1997)

J. Ross Quinlan

Versiones más modernas basadas en el C5.0...



Algoritmo para la obtención de un árbol de decisión

El árbol se construye de la forma **top-down recursive divide-and-conquer**.

Al comienzo, todas las muestras del dataset están en el nodo raíz.




El dataset se particiona recursivamente basado en los atributos seleccionados.

Los atributos se seleccionan en base a una heurística o una medida estadística.

Algoritmo para la obtención de un árbol de decisión


La partición continúa hasta que no tenga sentido seguir dividiendo el espacio.

- La subdivisión es pura (solo tiene muestras de la misma clase)
- La subdivisión tiene pocas muestras y/o no se justifica subdividir.
- No existe criterio para particionar (ambigüedad en el dataset).





Creación de un árbol de decisión

Altura	Peso	Clase
Alta	Alta	Rugby
Medio	Alto	Fútbol
Bajo	Alto	Fútbol
Medio	Medio	Voley
Bajo	Medio	Fútbol
Medio	Bajo	Voley
Bajo	Bajo	Fútbol




Árbol resultante




¿Es el único árbol que se puede construir a partir del dataset?

Árbol resultante (otro)



¿Qué atributo elegir para la partición?




¿Cuál de los dos
atributos elegir?

¿Con qué valor?

02

Métricas de desorden




Desorden

Existen varias formas de calcular el **desorden**, la **impureza** o la **incertidumbre** de un conjunto de datos.


Una métrica de **desorden** evalúa qué tan mezcladas están las clases dentro de un subconjunto de las muestras.

Desorden cero (0): El grupo es puro. Todos los elementos pertenecen a una sola clase.

Desorden máximo (1 o más): El grupo está totalmente mezclado. Hay la misma cantidad de elementos de cada clase



Particiones con bajo desorden






Particiones con alto desorden

Desorden

Nombre	Pelo	Estatura	Peso	Protector	Resultado
Sara	Rubio	Promedio	Ligero	No	Quemado
Diana	Rubio	Alta	Promedio	Si	Ninguno
Alexis	Castaño	Baja	Promedio	Si	Ninguno
Ana	Rubio	Baja	Promedio	No	Quemado
Emilia	Pelirrojo	Promedio	Pesado	No	Quemado
Pedro	Castaño	Alta	Pesado	No	Ninguno
Juan	Castaño	Promedio	Pesado	No	Ninguno
Catalina	Rubio	Baja	Ligero	Si	Ninguno

¿Qué atributo elegiría como raíz del árbol?

Calculamos el desorden que produciría cada atributo



Métricas de desorden

Índice GINI (usado en CART)

Entropía (usada en ID3)

Relación de ganancia (usada en C4.5)

Chi Cuadrado

Distancia de Towing

Entropía de Tsallis

El uso de distintas métricas sobre el mismo dataset puede producir resultados distintos (árboles distintos).



Cálculo de la entropía

La entropía producida por la selección de un atributo puede medirse como:

$$Entropía = \sum_b \left(\frac{n_b}{n_t}\right) * \left(\sum_c -\frac{n_{bc}}{n_b} \log_2 \frac{n_{bc}}{n_b}\right)$$

Donde

n_b es el número de muestras en la rama b ,


n_t es el número total de muestras en todas las ramas,

n_{bc} es el total de muestras en la rama b de la clase c .

Es un número real entre 0 y 1 que será más chico cuanto más homogéneos sean los subconjuntos que este atributo genere.

Entropía en una rama

Rama “Rubio” del atributo PELO




$$Entropía = \sum_c -\frac{n_{bc}}{n_b} \log_2 \frac{n_{bc}}{n_b}$$

$$Entropía = \underbrace{-\frac{2}{4} \log_2 \frac{2}{4}}_{\text{Quemado}} - \underbrace{\frac{2}{4} \log_2 \frac{2}{4}}_{\text{Ninguno}} = 1$$



Entropía en una rama

Rama “Castaño” del atributo PELO




$$Entropía = \sum_c -\frac{n_{bc}}{n_b} \log_2 \frac{n_{bc}}{n_b}$$

$$Entropía = \underbrace{-\frac{3}{3} \log_2 \frac{3}{3}}_{\text{Quemado}} - \underbrace{\frac{0}{3} \log_2 \frac{0}{3}}_{\text{Ninguno}} = 0$$



Entropía del atributo PELO



$$Entropía = \sum_b \left(\frac{n_b}{n_t} \right) * \left(\sum_c - \frac{n_{bc}}{n_b} \log_2 \frac{n_{bc}}{n_b} \right)$$

$$Entropía = \underbrace{\frac{4}{8} * 1}_{\text{Rubio}} + \underbrace{\frac{3}{8} * 0}_{\text{Castaño}} + \underbrace{\frac{1}{8} * 0}_{\text{Pelirrojo}} = 0.5$$


Entropía de cada atributo

Repitiendo el mismo proceso para el resto de los atributos se consigue la siguiente tabla:

Atributo	Entropía
Pelo	0.5
Estatura	0.69
Peso	0.94
Protector	0.61

Seleccionado
por ser el de
menor valor.

Algoritmo de obtención de un árbol de decisión




Ya tenemos el primer nodo del árbol.

Ahora hay que hacer lo mismo con las cuatro muestras de la rama "Rubio".

Calculamos, para ese subconjunto, la entropía del resto de los atributos: "Estatura", "Peso" y "Protector".

Algoritmo de obtención de un árbol de decisión

Atributo	Entropía
Estatura	0.5
Peso	1
Protector	0



¿Cuántos niveles tendrá como máximo un árbol con atributos discretos?

Entropía sobre atributos numéricos

#	Ambiente	Temperatura	Humedad	Viento	Juega
1	soleado	85	85	NO	No
2	soleado	80	90	SI	No
3	nublado	83	86	NO	Si
4	lluvioso	70	96	NO	Si
5	lluvioso	68	80	NO	Si
6	lluvioso	65	70	SI	No
7	nublado	64	65	SI	Si
8	soleado	72	95	NO	No
9	soleado	69	70	NO	Si
10	lluvioso	75	80	NO	Si
11	soleado	75	70	SI	Si
12	nublado	72	90	SI	Si
13	nublado	81	75	NO	Si
14	lluvioso	71	91	SI	No

Entropía sobre atributos numéricos

Para cada atributo numérico

Se ordenan sus valores de menor a mayor

Se calculan TODOS los posibles valores de desorden


Se elige el menor.

Humedad	65	70	75	80	85	86	90	91	95	96
	Si	No	Si	Si	No	Si	No	No	No	Si
		Si		SI			Si			
		Si								

Entropía sobre atributos numéricos



Humedad	65	70	75	80	85	86	90	91	95	96
	Si	No	Si	Si	No	Si	No	No	No	Si
		Si		SI			Si			
		Si								



Entropía sobre atributos numéricos


67.5	0.8926
72.5	0.9253
77.5	0.8950
82.5	0.7885
85.5	0.8922
88	0.8380
90.5	0.8610
93	0.9300
95.5	0.8926



Si calculamos TODOS los cortes posibles veremos que 0.7885 es el menor valor y por lo tanto es el punto de corte elegido para el atributo HUMEDAD



Árbol con atributos nominales y numéricos



¿Cuántos niveles tendrá como máximo un árbol con atributos numéricos?

Dataset de entrenamiento

Pregnancie	Glucos	BloodPressur	SkinThicknes	Insuli	BM	DiabetesPedigreeFunctio	Ag	Outcom
6	148	72	35	1695	336	627	50	1
1	85	66	29	1025	266	351	31	0
8	183	64	32	1695	233	672	32	1
1	89	66	23	94	281	167	21	0
0	137	40	35	168	431	2288	33	1
5	116	74	27	1025	256	201	30	0
3	78	50	32	88	31	248	26	1
10	115	70	27	1025	353	134	29	0
2	197	70	45	543	305	158	53	1
8	125	96	32	1695	343	232	54	1
4	110	92	27	1025	376	191	30	0
10	168	74	32	1695	38	537	34	1
10	139	80	27	1025	271	1441	57	0
1	189	60	23	846	301	398	59	1
5	166	72	19	175	258	587	51	1
7	100	745	32	1695	30	484	32	1
0	118	84	47	230	458	551	31	1
7	107	74	32	1695	296	254	31	1
1	103	30	38	83	433	183	33	0
1	115	70	30	96	346	529	32	1
3	126	88	41	235	393	704	27	0
8	99	84	27	1025	354	388	50	0
7	196	90	32	1695	398	451	41	1
9	119	80	35	1695	29	263	29	1
11	143	94	33	146	366	254	51	1
10	125	70	26	115	311	205	41	1
7	147	76	32	1695	394	257	43	1
1	97	66	15	140	232	487	22	0
13	145	82	19	110	222	245	57	0
5	117	92	27	1025	341	337	38	0
5	109	75	26	1025	36	546	60	0
3	158	76	36	245	316	851	28	1
3	88	58	11	54	248	267	22	0
6	92	92	27	1025	199	188	28	0
10	122	78	31	1025	276	512	45	0
4	103	60	33	192	24	966	33	0

El entrenamiento de un árbol es supervisado. Eso quiere decir que para poder armar o entrenar un árbol necesitamos para cada muestra, la salida o resultado esperado.

Crear un árbol con Scikit-learn

```
from sklearn.tree import DecisionTreeClassifier
import pandas as pd

# Dataset "Pima Indians Diabetes Dataset"
pima = pd.read_csv("diabetes.csv")

feature_cols = ['Pregnancies', 'Glucose', 'BloodPressure',
                 'SkinThickness', 'Insulin', 'BMI',
                 'DiabetesPedigreeFunction', 'Age']

X = pima[feature_cols]
T = pima.Outcome

clf = DecisionTreeClassifier()
model = clf.fit(X, T)
```

Crear un árbol con Scikit-learn

Parámetros de configuración:

- criterion:	{“gini”, “entropy”, “log_loss”}	default=“gini”
- max_depth:	int	default=None
- min_samples_split	int or float	default=2
- min_samples_leaf	int or float	default=1
- max_leaf_nodes	int	default=None

Algunos más en: <https://scikit-learn.org/stable/modules/generated/sklearn.tree.DecisionTreeClassifier.html>

```
clf = DecisionTreeClassifier(criterion="entropy", max_depth=5,  
                             min_samples_split=100, min_samples_leaf=40,  
                             max_leaf_nodes=6)  
  
model = clf.fit(X, T)
```

03

Visualización de un árbol de decisión




Fig. 1. Modelo de Árbol para los síntomas y signos.


Visualizando un árbol de decisión

```
from sklearn.tree import export_graphviz
from six import StringIO
from IPython.display import Image
import pydotplus



dot_data = StringIO()
export_graphviz(model, out_file=dot_data, filled=True,
                rounded=True, special_characters=True,
                feature_names = feature_cols,
                class_names = ['0', '1'])

graph = pydotplus.graph_from_dot_data(dot_data.getvalue())
graph.write_png('diabetes.png')
Image(graph.create_png())
```

Visualizando un árbol de decisión



Visualizando un árbol de decisión




Visualizando un árbol de decisión

```
from sklearn.tree import export_text
```


```
print(export_text(clf, feature_names = feature_cols))
```

```
|--- Ba <= 0.43
|   |--- Si <= 72.74
|   |   |--- class: 3
|   |   |--- Si > 72.74
|   |   |--- class: 2
|--- Ba > 0.43
|   |--- class: 7
```



A photograph of a wooden bed frame with a mattress shaped like the number 3, placed on a wooden floor.

iii Overfitting !!!






Actividad

1. Entrene un árbol de decisión utilizando el dataset “diabetes.csv”, usando:
 - criterion="entropy" y “gini”
 - max_depth=4¿Qué diferencias observa en los dos árboles resultantes?
2. ¿Cómo quedan los árboles si incluimos el atributo “Outcome” durante su obtención?
¿Tiene sentido el árbol obtenido?


04

Predicción de un árbol de decisión



Realizando predicciones


Ante una nueva muestra, siempre se comienza consultando por el nodo raíz.
Se va descendiendo por las ramas correspondientes hasta llegar a un nodo hoja, el cual nos dirá la predicción: a qué clase pertenece.



Realizando predicciones


¿A qué clase pertenecen estas muestras?

#	Ambiente	Temperatura	Humedad	Viento
101	nublado	83	86	NO
102	soleado	80	90	SI
103	lluvioso	70	96	NO
104	soleado	68	????	NO



Nodos impuros

En casos de nodos hoja impuros (posee muestras de varias clases), la respuesta suele ser la clase mayoritaria. Algunas implementaciones devuelven el nivel de confianza de cada clase.



#	Ambiente	Temperatura	Humedad	Viento	
105	soleado	83	72	NO	(NO: 57%; SI: 43%)
106	soleado	80	90	SI	

← (NO: 83%; SI: 17%)

Realizando predicciones

```
T_pred = model.predict(new_X)
```

Usando el árbol conseguido en la actividad anterior (usando entropy) y con los siguientes datos de un paciente ¿Cuál es la predicción dada por el modelo?

```
new_X = [[0, 150, 210, 30, 115, 30, 0.2, 25]]
```


¿Podemos confiar en la predicción?



05

Métricas de evaluación

Accuracy (Exactitud)



Métrica Accuracy (Exactitud)

Podemos medir la exactitud de un modelo revisando la clase predicha, con la clase real esperada.

$$\text{Accuracy} = \frac{\text{Muestras_bien_clasificadas}}{\text{Muestras_totales}}$$

Outcome ▾	Prediction ▾
1	1
0	0
1	0
0	1
1	0
0	1
1	1
0	0
1	1
1	1
0	0
1	1
0	0
1	0
1	1
1	1
1	1
1	1
0	1
1	0

¿Qué árbol debemos obtener para lograr una exactitud perfecta?

Métrica Accuracy (Exactitud)

```
from sklearn import metrics
```

```
T_pred = model.predict(X)
```

```
print("Accuracy:", metrics.accuracy_score(T, T_pred))
```

!!!! No es una buena práctica medir la exactitud de un modelo con las mismas muestras que fueron utilizadas durante el entrenamiento !!!!



Entreno con un subconjunto... evalúo con otro distinto

```
from sklearn.model_selection import train_test_split

X_train, X_test, T_train, T_test = train_test_split(X, T,
                                                    test_size=0.3,
                                                    random_state=13)

model = clf.fit(X_train, T_train)

T_pred = model.predict(X_test)
print("Accuracy: ", metrics.accuracy_score(T_test, T_pred))
```

Actividad

3. Separe el dataset “diabetes” en 90-10 (train-test).
4. Entrene dos árboles con los criterios “entropy” y “gini” (dejando el resto de los parámetros con sus valores por defecto. ¿Cuál es el accuracy alcanzado en ambos?
5. Entrene dos nuevos árboles usando los dos criterios anteriores y una profundidad máxima de 4 niveles ¿Compare los nuevos accuracy obtenidos con los del punto 2? ¿Por qué cree que sucede?
6. Entrene nuevamente los dos árboles anteriores, pero separando el dataset en: (80-20), (70-30), (60-40) ¿Qué sucede con los distintos accuracy obtenidos? ¿Por qué cree que sucede?



Actividad

7. Repita la actividad 6 utilizando el datasets “glass”.
El objetivo es, dada la características químicas de una muestra de vidrio, determinar a qué categoría pertenece (1 a 7)
8. Repita la actividad 6 utilizando el datasets “campus”.
El objetivo es, dada las características académicas de estudiantes, determinar si consiguió o no un empleo, luego de una entrevista.
Este dataset posee atributos nominales, los cuales deberán ser “numerizados” (utilizando codificación one-hot o mediante numerización ordinal, según el tipo de atributo) antes de entrenar un árbol.

RESUMEN

- Aprendizaje supervisado
- Árbol de clasificación
- Distintos árboles con el mismo dataset
- Separación de train-test
- Accuracy

