



UNIVERSIDAD
NACIONAL
DE LA PLATA

Minería de Datos y Aprendizaje Automático

Clase 2
Minería de Datos y Aprendizaje Automático

2026

Temario

1

Aprendizaje Automático

2

EDA – Análisis Exploratorio de Datos.

3

Preparación de los datos

4

Evaluación de Modelos

5

KNN – K-Vecinos más cercanos

01


Aprendizaje Automático



Machine Learning

El Aprendizaje Automático (Machine Learning) es una rama de la Inteligencia Artificial que estudia mecanismos que permite a las computadoras aprender a clasificar o predecir en base a experiencias.


El Machine Learning construye modelos estadísticos a partir de datos.



Machine Learning vs Estadística clásica



ENFOQUE ESTADÍSTICO:
Foco en Inferencia y Explicación



Intervalos de confianza
p-valores
Residuos normales
Test de hipótesis



ENFOQUE DE MACHINE LEARNING:
Foco en Predicción y Generalización



¿Cómo predice el modelo con
datos nuevos?
Métricas: Ej. MSE.

Machine Learning vs Estadística clásica

Aspecto	Estadística clásica	Machine Learning
Objetivo	Inferencia (explicar)	Predicción (generalizar)
Enfoque	Modelo → datos	Datos → modelo
Supuestos	Fuertes (normalidad, independencia, etc.)	Débiles o implícitos
Tamaño de datos	Pequeño–mediano	Grande
Interpretabilidad	Alta	Variable (en general baja)
Evaluación	Significancia, p-valores	Error de predicción, validación


La estadística busca comprender el mundo a partir de los datos; el Machine Learning busca predecirlo.

Minería de Datos




Proceso matemático y estadístico para extraer patrones ocultos e información procesable a partir de grandes volúmenes de información

Proceso KDD Knowledge Discovery in Databases (Descubrimiento de Conocimiento en Bases de Datos).




Nombres




Metodología CRISP-DM

(Cross-Industry Standard Process for Data Mining)



Metodología CRISP-DM




En la práctica,

- Como regla general se gasta más del 80% del tiempo preparando los datos,
- y menos del 20% creando un modelo.

Interpretabilidad de Modelos

Modelos de caja blanca




Es posible interpretar el modelo:

- Regresión lineal
- Reglas – árboles
- Modelos probabilísticos

Vs.

Modelos de caja negra



NO es posible interpretar el modelo:


- Redes Neuronales
- Deep Learning

Interpretabilidad de Modelos

Modelos de caja blanca




Árbol de clasificación



Modelos de caja negra




Redes Neuronales



¿Qué puede hacer un modelo ?

Regresión




Clasificación



Agrupamiento
(clustering)




Reducción
dimensionalidad



Generación




Toma de decisiones



Machine Learning

Aprendizaje Supervisado


Existe una clase /etiqueta.



- Redes Neuronales (Deep Learning)
- Regresión lineal
- Máquinas de Vectores Soporte
- Random Forest


Aprendizaje No Supervisado

No existe información de clase.
Se agrupan los datos con características similares.



- Clustering (k-means, DBSCAN, etc.)
- Descripción y Visualización

Problemas de Regresión



Se desea predecir el consumo de un automóvil a partir de datos anteriores.


El modelo va a tener un error (ya que muy pocos elementos pasan por la recta), pero es simple y funciona “bien”.

$$y = 0.2X + 7$$

Problemas de Regresión

Imágenes

Input:
una imagen




output:
Número real

Ejemplo: estimar la edad de una persona.



Problemas de Regresión

Reconstrucción de imágenes



Problemas de Clasificación

Clasificación binaria





Perro

No Perro



Problemas de Clasificación

Clasificación multiclase



Gato


Perro

Ave


Rana

Ciervo

Problemas de Clasificación




K-Nearest Neighbors




Neural Networks

Modelo



Support vector machine



Random Forest



Gato

Perro


Ave

Rana

Ciervo

Clustering


(No Supervisado)




Reducción Dimensionalidad

(No Supervisado)

Manifold Learning with 1000 points, 10 neighbors




Modelos generativos




Entrenamiento de un modelo

- Proceso iterativo
- Minimización de una función de error
- Ejemplo para regresión lineal: Error Cuadrático Medio



Función de error



Métricas

¿Cómo medir la eficacia del modelo?

Regresión: MAE, MSE, R^2 , etc.

Clasificación: Accuracy, Precision, Recall, etc.

Agrupamiento: Silhouette Score, Davies-Bouldin Index, etc.

Generativos: Log-Likelihood, Perplexity, FID, IS, etc.



¿Cuándo NO usar Machine Learning?


Limitaciones del ML:

1. **El problema es determinista:** Si existe una fórmula física o una lógica exacta (ej. calcular impuestos, fórmula física).
2. **No hay datos:** Sin datos, volvemos a la IA basada en reglas o conocimiento experto.



02


Análisis Exploratorio de Datos



Análisis Exploratorio de Datos (EDA)

El objetivo es entender la estructura, calidad y patrones de los datos.

- Identificar valores faltantes o errores
- Analizar distribuciones de variables
- Detectar outliers
- Observar relaciones entre variables
- ¿Los datos están distribuidos en diferentes fuentes?



Datos

Para hacer Machine Learning necesitamos DATOS

Datos tabulares

	A	B	C	D	E
1	sepal.length	sepal.width	petal.length	petal.width	class
2	5,10	3,50	1,40	0,20	Iris-setosa
3	4,90	3,00	1,40	0,20	Iris-setosa
4	4,70	3,20	1,30	0,20	Iris-setosa
5	4,60	3,20	1,40	0,20	Iris-setosa
6	5,30	3,70	1,50	0,20	Iris-setosa
7	5,00	3,30	1,40	0,20	Iris-setosa
8	7,00	3,20	4,70	1,40	Iris-versicolor
9	6,40	3,20	4,50	1,50	Iris-versicolor
10	6,90	3,10	4,90	1,50	Iris-versicolor
11	5,50	2,30	4,00	1,30	Iris-versicolor
12	7,60	3,00	6,60	2,10	Iris-virginica
13	4,90	2,50	4,50	1,70	Iris-virginica
14	7,30	2,90	6,30	1,80	Iris-virginica
15	6,70	2,50	5,80	1,80	Iris-virginica
16	7,20	3,60	6,10	2,50	Iris-virginica
17	6,50	3,20	5,10	2,00	Iris-virginica
18	6,40	2,70	5,30	1,90	Iris-virginica
19	6,80	3,00	5,50	2,10	Iris-virginica

Datos multimedia



Datos

- **Origen de datos:** Múltiples fuentes dispersas o heterogéneas.
- **Objetivo:** Construir una vista minable.
- **¿Qué es una vista minable?** Una estructura unificada y plana (donde cada fila es una instancia y cada columna un atributo), preparada específicamente para entrenar un modelo de DM/ML.



Ejemplo Dataset tabular

IRIS Dataset - Datos estructurados

- Almacenado en un archivo “csv” (Comma Separated Values).
- Cada fila es un registro (un ejemplo)
- Cada columna es un atributo (variable o feature)
- 3 especies distintas de flores (clases).
- Dos tipos de datos: numéricos y nominales.


	A	B	C	D	E
1	sepal_length	sepal_width	petal_length	petal_width	name
2	5.1	3.5	1.4	0.2	setosa
3	4.9	3.0	1.4	0.2	setosa
4	4.7	3.2	1.3	0.2	setosa
5	4.6	3.1	1.5	0.2	setosa
6	5.0	3.6	1.4	0.2	setosa
7	5.4	3.9	1.7	0.4	setosa
8	4.6	3.4	1.4	0.3	setosa
9	5.0	3.4	1.5	0.2	setosa




Visualización

Visualizar los datos puede ser una tarea esencial para entender el dominio en el que estamos trabajando.


Al tener más de 2 variables, visualizar puede no ser trivial.



Visualización




Visualización. 2 variables




- Al tener 2 atributos podemos hacer un gráfico 2D.
- ¿Qué sucede al tener 4 atributos?

Visualización. Pairplot




Visualización - Reducción de dimensionalidad

Ej. PCA




Visualización - Reducción de dimensionalidad

Ej. t-SNE




Visualización - Reducción de dimensionalidad

Reducción $\neq$ Feature Selection




Visualización - Reducción de dimensionalidad

Acciones humanas
(561 variables)



t-SNE

Reducción a 2 variables



Matplotlib


```
import matplotlib.pyplot as plt
import numpy as np

# crea las variables con los datos
x= np.arange(0, 360)
y= np.sin(x * np.pi / 180.)

# Crear el gráfico
plt.plot(x,y)

# Añadir etiquetas y título (opcional)
plt.xlabel('ángulo')
plt.ylabel('seno(x) ')
plt.title('Seno de x entre 0 y 360º')
plt.grid()

# guarda el grafico en una imagen png
plt.savefig('figura.png')
```





Pandas

<https://pandas.pydata.org/>

- Pandas es una librería de código abierto, fácil de usar, que provee manejo para carga y análisis de datos, entre otras funcionalidad.
- Es una librería muy utilizada para cargar archivos CSV o XLS.
- Cada columna tiene nombres, y pueden contener información de diferente tipo.
- Muchas funciones de visualización y preprocesamiento.

Pandas – Exploración de datos

Cargar Iris Dataset con Pandas

```
import pandas as pd  
iris = pd.read_csv("iris.csv")
```

Crea un DataFrame



Pandas – Exploración de datos

Con este comando podemos ver los primeros datos en el dataframe.

```
iris.head()
```

	sepal_length	sepal_width	petal_length	petal_width	name
0	5.1	3.5	1.4	0.2	setosa
1	4.9	3.0	1.4	0.2	setosa
2	4.7	3.2	1.3	0.2	setosa
3	4.6	3.1	1.5	0.2	setosa
4	5.0	3.6	1.4	0.2	setosa

Pandas – Exploración de datos

Con este comando podemos ver un análisis estadístico rápido de las variables.

```
iris.describe()
```

	sepal_length	sepal_width	petal_length	petal_width
count	150.000000	150.000000	150.000000	150.000000
mean	5.843333	3.054000	3.758667	1.198667
std	0.828066	0.433594	1.764420	0.763161
min	4.300000	2.000000	1.000000	0.100000
25%	5.100000	2.800000	1.600000	0.300000
50%	5.800000	3.000000	4.350000	1.300000
75%	6.400000	3.300000	5.100000	1.800000
max	7.900000	4.400000	6.900000	2.500000

Pandas – Exploración de datos

Cuenta la cantidad de ítems en la columna seleccionada.


```
iris['name'].value_counts()
```

versicolor	50
setosa	50
virginica	50

Pandas – Exploración de datos

Gráfico de barras de la media de cada atributo, diferenciado por clase.


```
plot_data= iris.groupby('name').mean()  
plot_data.plot(kind='bar')
```



Pandas – Exploración de datos

Crea un histograma para
cada columna del
dataframe




```
iris.hist()
```



Plotly express

Plotly Express es una API concisa, consistente y de alto nivel para crear figuras en python.

<https://plotly.com/python/plotly-express/>



Plotly express

Matriz de correlación entre features

```
fig = px.imshow(  
    iris.corr(),  
    text_auto=True,  
    aspect="auto",  
    color_continuous_scale=  
        px.colors.sequential.RdBu  
)
```



Plotly express


```
import plotly.express as px
import numpy as np

# crea las variables con los datos
x = np.arange(0, 360)
y = np.sin(x * np.pi / 180.)

# Crear el gráfico con Plotly Express
fig = px.line(x=x, y=y,
              labels={'x': 'ángulo',
                     'y': 'seno(x)'},
              title='Seno de x entre 0 y 360°')


# Mostrar el gráfico
fig.show()
```

Seno de x entre 0 y 360°



Plotly express


Gráfico de dispersión de dos variables



```
import plotly.express as px
df = px.data.iris()
fig = px.scatter(df, x="sepal_width", y="sepal_length",
                 color="name", marginal_y="violin",
                 marginal_x="box", trendline="ols",
                 template="simple_white")
fig.show()
```

```
import plotly.express as px
df = px.data.iris()
df_boxplot = df.melt(id_vars=['name'],
                    var_name='feature', value_name='value')
fig_boxplot_new = px.box(df_boxplot, x='feature',
                        y='value', color='name')
fig.show()
```


Diagrama de cajas



Plotly express

Matriz con scatter 2D
para cada par de features
(Cuidado si son muchos
features !)

```
fig = px.scatter_matrix(  
    iris,  
    dimensions= iris.feature_names,  
    color="name",  
    title="Scatter Plot Matrix del Conjunto de Datos Iris")  
fig.show()
```






Seaborn visualization

Seaborn es una biblioteca de visualización de datos en Python basada en matplotlib. Proporciona una interfaz de alto nivel para dibujar gráficos estadísticos atractivos e informativos.

<https://seaborn.pydata.org/>


<https://www.kaggle.com/code/noelano/seaborn-visualization-on-iris-data-set>





Seaborn visualization

```
sns.boxplot(data=iris)
```




03

Preparación de los datos

male	22.0	1	0	A/5 21171	7.25	NaN	S
female	38.0	1	0	PC 17599	71.2833	C85	C
female	26.0	0	0	STON/O2. 3101282	7.925	NaN	S
female	35.0	1	0	113803	53.1	C123	S
male	35.0	0	0	373450	8.05	NaN	S
male	NaN	0	0	330877	8.4583	NaN	Q
male	54.0	0	0	17463	51.8625	E46	S
male	2.0	3	1	349909	21.075	NaN	S
female	27.0	0	2	347742	11.1333	NaN	S
female	14.0	1	0	237736	30.0708	NaN	C
female	4.0	1	1	PP 9549	16.7	G6	S
female	58.0	0	0	113783	26.55	C103	S
male	20.0	0	0	A/5. 2151	8.05	NaN	S
male	39.0	1	5	347082	31.275	NaN	S
female	14.0	0	0	350406	7.8542	NaN	S
female	55.0	0	0	248706	16.0	NaN	S
male	2.0	4	1	382652	29.125	NaN	Q
male	NaN	0	0	244373	13.0	NaN	S
female	31.0	1	0	345763	18.0	NaN	S
female	NaN	0	0	2649	7.225	NaN	C
male	35.0	0	0	239865	26.0	NaN	S
male	34.0	0	0	248698	13.0	D56	S
female	15.0	0	0	330923	8.0292	NaN	Q
male	28.0	0	0	113788	35.5	A6	S
female	8.0	3	1	349909	21.075	NaN	S

Preprocesamiento de los datos



3 pasos importantes (para datos tabulares):

- **Revisar valores nulos/faltantes**

Un dataset real puede tener muchos registros corruptos

- **Manejar datos nominales**


Pasar de texto a números

- **Normalizar datos**

Los modelos de ML en general necesitan datos normalizados.

Preprocesamiento de los datos.

Ej. Titanic Dataset



PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
1	0.0	3	Braund, Mr. Owen Harris	male	22.0	1	0	A/5 21171	7.25	NaN	S
2	1.0	1	Cumings, Mrs. John Bradley (Florence Briggs Thayer)	female	38.0	1	0	PC 17599	71.2833	C85	C
3	1.0	3	Heikkinen, Miss. Laina	female	26.0	0	0	STON/O2. 3101282	7.925	NaN	S
4	1.0	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	0	113803	53.1	C123	S
5	0.0	3	Allen, Mr. William Henry				0	373450	8.05	NaN	S
6	0.0	3	Moran, Mr. James				0	330877	8.4583	NaN	Q
7	0.0	1	McCarthy, Mr. Timothy J				0	17463	51.8625	E46	S
8	0.0	3	Palsson, Master. Gosta Leonard	male	2.0	3	1	349909	21.075	NaN	S
9	1.0	3	Johnson, Mrs. Oscar W (Elisabeth Vilhelmina Berg)	female	27.0	0	2	347742	11.1333	NaN	S
10	1.0	2	Nasser, Mrs. Nicholas (Adele Achem)	female	14.0	1	0	237736	30.0708	NaN	C
11	1.0	3	Sandstrom, Miss. Marguerite Rut	female	4.0	1	1	PP 9549	16.7	G6	S
12	1.0	1	Bonnell, Miss. Elizabeth	female	58.0	0	0	113783	26.55	C103	S
13	0.0	3	Saunderscock, Mr. William Henry	male	20.0	0	0	A/5. 2151	8.05	NaN	S
14	0.0	3	Andersson, Mr. Anders Johan	male	39.0	1	5	347082	31.275	NaN	S
15	0.0	3	Vestrom, Miss. Hulda Amanda Adolfina	female	14.0	0	0	350406	7.8542	NaN	S
16	1.0	2	Hewlett, Mrs. (Mary D Kingcome)	female	55.0	0	0	248706	16.0	NaN	S
17	0.0	3	Rice, Master. Eugene	male	2.0	4	1	382652	29.125	NaN	Q
18	1.0	2	Williams, Mr. Charles Eugene	male	NaN	0	0	244373	13.0	NaN	S
19	0.0	3	Vander Planke, Mrs. Julius (Emelia Maria Vandemoortele)	female	31.0	1	0	345763	18.0	NaN	S
20	1.0	3	Masselmani, Mrs. Fatima	female	NaN	0	0	2649	7.225	NaN	C
21	0.0	2	Fynney, Mr. Joseph J	male	35.0	0	0	239865	26.0	NaN	S
22	1.0	2	Beesley, Mr. Lawrence	male	34.0	0	0	248698	13.0	D56	S
23	1.0	3	McGowan, Miss. Anna "Annie"	female	15.0	0	0	330923	8.0292	NaN	Q
24	1.0	1	Sloper, Mr. William Thompson	male	28.0	0	0	113788	35.5	A6	S
25	0.0	3	Palsson, Miss. Torborg Danira	female	8.0	3	1	349909	21.075	NaN	S

Nominales

Valores nulos



Datos Nominales. Codificaciones.

Técnica	Cómo funciona	Cuándo usarla
Categorical /Ordinal Encoding	Asigna un número entero único a cada categoría (ej. "Bajo" = 0, "Medio" = 1, "Alto" = 2).	Variables ordinales (donde existe una jerarquía o un orden lógico).
One-Hot Encoding	Crea una nueva columna binaria (0 o 1) por cada posible string (ej. columna_perro, columna_gato).	Variables nominales (categorías sin jerarquía, como colores, ciudades o especies).

Datos Nominales. Codificaciones.

One-Hot Encoding

Datos originales

Color
Rojo
Azul
Verde
Rojo



Después de One-Hot Encoding

Rojo	Azul	Verde
1	0	0
0	1	0
0	0	1
1	0	0



- ✓ Crea una nueva columna binaria para cada categoría.
- ✓ Aumenta la dimensionalidad.
- ✓ Útil cuando el modelo no asume relación ordinal entre categorías.

Categorical Encoding

Datos originales

Color
Rojo
Azul
Verde
Rojo



Después de Categorical Encoding

Color (cód.)
0
1
2
0



- ✓ Asigna un número entero a cada categoría.
- ✓ No aumenta la dimensionalidad.
- ✓ Más eficiente, pero el modelo puede interpretar un orden entre categorías.

Nominal a Categórico / Ordinal

Convertir atributo nominal a categóricos/ordinal (setosa=0, vers= 1, virg= 2).

```
iris.name= pd.Categorical(iris.name)  
iris.name= iris.name.cat.codes
```

Guardar previamente los
nombres de las etiquetas

```
Labels= np.unique(iris.name)
```

Índice	sepal_length	sepal_width	petal_length	petal_width	name
0	5	2	3.5	1	1
1	6	2.2	5	1.5	2
2	6.2	2.2	4.5	1.5	1
3	6	2.2	4	1	1
4	5	2.3	3.3	1	1
5	6.3	2.3	4.4	1.3	1
6	5.5	2.3	4	1.3	1
7	4.5	2.3	1.3	0.3	0

Nominal a One-hot

- Cambiar un atributo nominal (texto) a codificación one-hot.
- La codificación one-hot tiene tantas columnas como etiquetas existan, pero solo una está activa a la vez.
- Se utiliza cuando no queremos mantener relación de orden.

```
iris= pd.get_dummies(data=iris, columns=['name'])
```

sepal_length	sepal_width	petal_length	petal_width	name_setosa	name_versicolor	name_virginica
4.5	2.3	1.3	0.3	1	0	0
4.4	3.2	1.3	0.2	1	0	0
5	3.5	1.6	0.6	1	0	0
			0.4	1	0	0
			0.3	1	0	0
5.1	3.8	1.6	0.2	1	0	0
4.6	3.2	1.4	0.2	1	0	0
5.3	3.7	1.5	0.2	1	0	0
5	3.3	1.4	0.2	1	0	0
7	3.2	4.7	1.4	0	1	0
6.4	3.2	4.5	1.5	0	1	0

Valores nulos

¿Qué hacer con los valores nulos?

No siempre es simple la decisión.

- **Eliminar filas:** Es la opción más usual. Eliminar todo el registro.
- **Eliminar Columnas:** otra opción puede ser eliminar una variable particular que contenga una proporción muy grande de valores nulos.
- **Reemplazar:** Se debe tener mucho cuidado en este caso, ya que estamos inventando los datos. Existe diferentes aproximaciones:
 - **Reemplazar por la media:** Muy peligroso en Machine Learning! Podrían quedar registros incoherentes.
 - **Reemplazar por un valor** calculado con una regresión u otro algoritmo de ML.
 - **Análisis experto.** En ocasiones la respuesta puede ser más simple de lo imaginado si conocemos bien el dominio.

Detectar y eliminar valores nulos

Reporte de valores nulos por columna

```
df.isnull().sum()
```

Detectar cantidad total de valores nulos

```
df.isnull().sum().sum()
```

Eliminar cualquier fila con valores nulos

```
df= df.dropna()
```



```
titanic_df.isnull().sum()
```

	0
survived	0
pclass	0
sex	0
age	177
sibsp	0
parch	0
fare	0
embarked	2
class	0

Eliminar Columnas

Eliminar la columna "Survived".

```
X = df.drop('Survived', axis=1)
```


Eliminar varias columnas

```
columns_to_drop = ['PassengerId', 'Name', 'Ticket', 'Cabin']  
df= df.drop(columns=columns_to_drop)
```

Normalización de datos


- Para muchos modelos es necesario que cada variable se encuentre en un rango similar al resto.
- Necesitamos entonces normalizar los rangos de algún modo

Ej. Iris Dataset




Normalización de datos

Min-max (0-1): $x = (x - \min(x)) / (\max(x) - \min(x))$




Normalización de datos

Z-score (μ y σ): $x = (x - \text{mean}(x)) / \text{std}(x)$



Preprocesamiento de los datos.


Ej. Titanic Dataset



PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
1	0.0	3	Braund, Mr. Owen Harris	male	22.0	1	0	A/5 21171	7.25	NaN	S
2	1.0	1	Cumings, Mrs. John Bradley (Florence Briggs Thayer)	female	38.0	1	0	PC 17599	71.2833	C85	C
3	1.0	3	Heikkinen, Miss. Laina	female	26.0	0	0	STON/O2. 3101282	7.925	NaN	S
4	1.0	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	0	113803	53.1	C123	S
5	0.0	3	Allen, Mr. William Henry				0	373450	8.05	NaN	S
6	0.0	3	Moran, Mr. James				0	330877	8.4583	NaN	Q
7	0.0	1	McCarthy, Mr. Timothy J				0	17463	51.8625	E46	S
8	0.0	3	Palsson, Master. Gosta Leonard	male	2.0	3	1	349909	21.075	NaN	S
9	1.0	3	Johnson, Mrs. Oscar W (Elisabeth Vilhelmina Berg)	female	27.0	0	2	347742	11.1333	NaN	S
10	1.0	2	Nasser, Mrs. Nicholas (Adele Achem)	female	14.0	1	0	237736	30.0708	NaN	C
11	1.0	3	Sandstrom, Miss. Marguerite Rut	female	4.0	1	1	PP 9549	16.7	G6	S
12	1.0	1	Bonnell, Miss. Elizabeth	female	58.0	0	0	113783	26.55	C103	S
13	0.0	3	Saunders, Mr. William Henry	male	20.0	0	0	A/5. 2151	8.05	NaN	S
14	0.0	3	Andersson, Mr. Anders Johan	male	39.0	1	5	347082	31.275	NaN	S
15	0.0	3	Vestrom, Miss. Hulda Amanda Adolfina	female	14.0	0	0	350406	7.8542	NaN	S
16	1.0	2	Hewlett, Mrs. (Mary D Kingcome)	female	55.0	0	0	248706	16.0	NaN	S
17	0.0	3	Rice, Master. Eugene	male	2.0	4	1	382652	29.125	NaN	Q
18	1.0	2	Williams, Mr. Charles Eugene	male	NaN	0	0	244373	13.0	NaN	S
19	0.0	3	Vander Planke, Mrs. Julius (Emelia Maria Vandemoortele)	female	31.0	1	0	345763	18.0	NaN	S
20	1.0	3	Masselmani, Mrs. Fatima	female	NaN	0	0	2649	7.225	NaN	C
21	0.0	2	Fynney, Mr. Joseph J	male	35.0	0	0	239865	26.0	NaN	S
22	1.0	2	Beesley, Mr. Lawrence	male	34.0	0	0	248698	13.0	D56	S
23	1.0	3	McGowan, Miss. Anna "Annie"	female	15.0	0	0	330923	8.0292	NaN	Q
24	1.0	1	Sloper, Mr. William Thompson	male	28.0	0	0	113788	35.5	A6	S
25	0.0	3	Palsson, Miss. Torborg Danira	female	8.0	3	1	349909	21.075	NaN	S


Nominales

Valores nulos




Preprocesamiento de los datos.

Ej. Titanic Dataset



Pclass	Sex	Age	SibSp	Parch	Fare	Embarked_C	Embarked_Q	Embarked_S
-1.5102393495530753	1.2831646924331173	0.10583160652576172	0.54150547281876	-0.509649135032208	1.3801010594812486	2.1656407827707715	-0.22749946679874952	-1.8561553006146871
-0.31006310668198594	-0.7793231889071193	-0.7942389809661147	-0.5358253454815004	-0.509649135032208	-0.42993626288302345	-0.46175709653961017	-0.22749946679874952	0.5387480237611791
0.8901131361891034	-0.7793231889071193	0.244304004601435	-0.5358253454815004	-0.509649135032208	-0.49618425134587696	-0.46175709653961017	-0.22749946679874952	0.5387480237611791
0.8901131361891034	1.2831646924331173	-0.6557665828904413	-0.5358253454815004	-0.509649135032208	-0.4804003346315729	-0.46175709653961017	-0.22749946679874952	0.5387480237611791
0.8901131361891034	-0.7793231889071193	-0.7250027819282779	-0.5358253454815004	-0.509649135032208	-0.5144135636074675	-0.46175709653961017	4.3956146977901245	-1.8561553006146871
-1.5102393495530753	-0.7793231889071193	1.9752089805473512	-0.5358253454815004	-0.509649135032208	-0.10625481589673265	2.1656407827707715	-0.22749946679874952	-1.8561553006146871
0.8901131361891034	-0.7793231889071193	-0.7942389809661147	0.54150547281876	0.6456909360169009	-0.27498710865950377	-0.46175709653961017	-0.22749946679874952	0.5387480237611791
0.8901131361891034	-0.7793231889071193	-0.24034938866342148	-0.5358253454815004	-0.509649135032208	-0.49403586020324264	-0.46175709653961017	-0.22749946679874952	0.5387480237611791
0.8901131361891034	-0.7793231889071193	-0.3788217867390948	-0.5358253454815004	-0.509649135032208	-0.5090781551406605	-0.46175709653961017	-0.22749946679874952	0.5387480237611791
-1.5102393495530753	-0.7793231889071193	0.8674297959419648	-0.5358253454815004	-0.509649135032208	-0.16694508720666215	-0.46175709653961017	-0.22749946679874952	0.5387480237611791
-0.31006310668198594	1.2831646924331173	-0.17111318962558486	0.54150547281876	-0.509649135032208	-0.3879946169254537	2.1656407827707715	-0.22749946679874952	-1.8561553006146871
-1.5102393495530753	-0.7793231889071193	1.005902194017638	1.6188362911190206	-0.509649135032208	0.9661622859314726	-0.46175709653961017	4.3956146977901245	-1.8561553006146871
0.8901131361891034	-0.7793231889071193	-0.30958558770125816	-0.5358253454815004	-0.509649135032208	-0.505965833535023	2.1656407827707715	-0.22749946679874952	-1.8561553006146871
-1.5102393495530753	1.2831646924331173	0.9366659949798014	-0.5358253454815004	0.6456909360169009	3.1241127020687838	-0.46175709653961017	-0.22749946679874952	0.5387480237611791
0.8901131361891034	1.2831646924331173	-0.7250027819282779	0.54150547281876	-0.509649135032208	-0.4947757035106399	-0.46175709653961017	-0.22749946679874952	0.5387480237611791
-0.31006310668198594	-0.7793231889071193	0.45201260171494495	0.54150547281876	1.8010310070660098	-0.1409349709309781	-0.46175709653961017	-0.22749946679874952	0.5387480237611791
0.8901131361891034	1.2831646924331173	-0.5865303838526047	-0.5358253454815004	-0.509649135032208	-0.49662886871811085	-0.46175709653961017	4.3956146977901245	-1.8561553006146871
-1.5102393495530753	1.2831646924331173	1.213610791131148	0.54150547281876	0.6456909360169009	0.30020015804360184	-0.46175709653961017	-0.22749946679874952	0.5387480237611791
0.8901131361891034	-0.7793231889071193	-1.902018165571501	3.773497927719542	0.6456909360169009	0.07136982431071678	-0.46175709653961017	-0.22749946679874952	0.5387480237611791
-1.5102393495530753	-0.7793231889071193	-0.17111318962558486	0.54150547281876	-0.509649135032208	0.3099070445142127	-0.46175709653961017	-0.22749946679874952	0.5387480237611791
-0.31006310668198594	1.2831646924331173	-0.5172941848147681	0.54150547281876	0.6456909360169009	-0.11870410231928229	-0.46175709653961017	-0.22749946679874952	0.5387480237611791
0.8901131361891034	-0.7793231889071193	-0.17111318962558486	-0.5358253454815004	-0.509649135032208	-0.4032592205489885	-0.46175709653961017	-0.22749946679874952	0.5387480237611791
0.8901131361891034	1.2831646924331173	0.31354020363927165	-0.5358253454815004	-0.509649135032208	-0.4032592205489885	-0.46175709653961017	-0.22749946679874952	0.5387480237611791
0.8901131361891034	-0.7793231889071193	-0.6557665828904413	-0.5358253454815004	-0.509649135032208	-0.5090781551406605	-0.46175709653961017	-0.22749946679874952	0.5387480237611791
0.8901131361891034	1.2831646924331173	1.0751383930554748	-0.5358253454815004	-0.509649135032208	-0.3943668731043102	-0.46175709653961017	-0.22749946679874952	0.5387480237611791

Dataset Curado y Normalizado




04


Evaluación de Modelos



Evaluación de modelos de ML



Evaluación de modelos de ML



Analogía:


Enseñar a multiplicar

- Práctica: 10 ejercicios
- Examen: los mismos 10 ejercicios
 - ¿aprenden el dominio? o ¿memorizan los resultados?

$\begin{array}{r} 142 \\ \times 309 \\ \hline 1,278 \\ 42,600 \\ \hline 43,878 \end{array}$	$\begin{array}{r} 883 \\ \times 470 \\ \hline 61,810 \\ 353,200 \\ \hline 415,010 \end{array}$	$\begin{array}{r} 556 \\ \times 288 \\ \hline 4,448 \\ 44,480 \\ 111,200 \\ \hline 160,128 \end{array}$	$\begin{array}{r} 491 \\ \times 622 \\ \hline 982 \\ 9,820 \\ 294,600 \\ \hline 305,402 \end{array}$	$\begin{array}{r} 321 \\ \times 508 \\ \hline 2,568 \\ 160,500 \\ \hline 163,068 \end{array}$
$\begin{array}{r} 554 \\ \times 628 \\ \hline 4,432 \\ 11,080 \\ 332,400 \\ \hline 347,912 \end{array}$	$\begin{array}{r} 668 \\ \times 664 \\ \hline 2,672 \\ 40,080 \\ 400,800 \\ \hline 443,552 \end{array}$	$\begin{array}{r} 469 \\ \times 909 \\ \hline 4,221 \\ 422,100 \\ 426,321 \end{array}$	$\begin{array}{r} 887 \\ \times 138 \\ \hline 7,096 \\ 26,610 \\ 88,700 \\ \hline 122,406 \end{array}$	$\begin{array}{r} 908 \\ \times 219 \\ \hline 8,172 \\ 9,080 \\ 181,600 \\ \hline 198,852 \end{array}$

¿Qué sería aprender los datos “de memoria” en Machine Learning?

- Podríamos tener un polinomio que pase exactamente por todos los patrones de entrenamiento.
- Spoiler: overfitting.
- ¿Cómo medimos esto?



Evaluación de modelos


Lo que haremos:

- Métrica con datos de Evaluación

Analogía:

Enseñar a multiplicar

- Práctica: 10 ejercicios
- Examen: 5 ejercicios nuevos
¿aprenden el dominio? o
¿memorizan los resultados?



Evaluación de modelos

Conjunto de evaluación

- Sinónimos: Test Set, Testing set, datos de prueba.
- Deberían tener el mismo formato que los datos de entrenamiento.
- Generalmente se obtienen de la misma base de datos.
 - Dividir en dos conjuntos
 - Generalmente 80%- 20%



Cómo generar conjunto de evaluación

División Estratificada Aleatoria

- 12 ejemplos
 - 3 Quemados - 9 Ninguno
- Divido $\frac{2}{3}$ y $\frac{1}{3}$
 - **Train:** $\frac{2}{3} = 66\% = 8$ ej
 - **Test:** $\frac{1}{3} = 33\% = 4$ ej
- Estratificada y aleatoria
 - Misma proporción de clases
 - Orden Aleatorio

Nombre	Pelo	Estatura	Peso	Protector	Resultado
Sara	Rubio	Promedio	Ligero	No	Quemado
Ana	Rubio	Baja	Promedio	No	Ninguno
Pedro	Castaño	Alta	Pesado	No	Ninguno
Felipe	Pelirrojo	Promedio	Pesado	No	Ninguno

Dataset original

Nombre	Pelo	Estatura	Peso	Protector	Resultado
Sara	Rubio	Promedio	Ligero	No	Quemado
Diana	Rubio	Alta	Promedio	Si	Quemado
Alexis	Rubio	Baja	Promedio	Si	Ninguno
Ana	Rubio	Baja	Promedio	No	Ninguno
Emilia	Rubio	Promedio	Pesado	No	Quemado
Pedro	Castaño	Alta	Pesado	No	Ninguno
Jacinta	Castaño	Alta	Promedio	Si	Ninguno
María	Castaño	Baja	Promedio	No	Ninguno
Juan	Castaño	Promedio	Pesado	No	Ninguno
Catalina	Castaño	Baja	Ligero	Si	Ninguno
Felipe	Pelirrojo	Promedio	Pesado	No	Ninguno
Roberta	Pelirrojo	Alta	Ligero	Si	Ninguno

Train

Test

Nombre	Pelo	Estatura	Peso	Protector	Resultado
Diana	Rubio	Alta	Promedio	Si	Quemado
Alexis	Rubio	Baja	Promedio	Si	Ninguno
Emilia	Rubio	Promedio	Pesado	No	Quemado
Jacinta	Castaño	Alta	Promedio	Si	Ninguno
María	Castaño	Baja	Promedio	No	Ninguno
Juan	Castaño	Promedio	Pesado	No	Ninguno
Catalina	Castaño	Baja	Ligero	Si	Ninguno
Roberta	Pelirrojo	Alta	Ligero	Si	Ninguno

Evaluación de modelos


Métrica en ambos conjuntos

- **Métrica en Train set:** ¿Fue entrenado correctamente el modelo?
- **Métrica en Test set:** ¿Cómo se comporta el modelo con datos nuevos?



Ejemplo Training / Testing

**Dataset de
Regresión dividido
aleatoriamente**




Validación cruzada


- Una sola evaluación no es suficiente (muchos componentes estocásticos).

- **Validación cruzada**

- ✓ Realizar varias ejecuciones independientes y promediar.




K-fold cross-validation





- Variante: Estratificada

Validación cruzada aleatoria (ShuffleSplit)




- Variante: Estratificada

Ejemplo Partición ShuffleSplit



Ejemplo Partición ShuffleSplit Estratificada





Cross Validation. Ejemplo real.



Otras formas de división Train/Test

Existen casos donde se divide con otras estrategias más específicas.



- Ej: División Espacial



Abbate N, Gasparini L, Quiroga F, Ronchetti F. "High-Resolution Income Estimates Using Satellite Imagery: A Deep Learning Approach Applied in Buenos Aires". Latin American Computer Conference (CLEI). Págs. 1-4. Agosto 2024.

Otras formas de división Train/Test

- Ej: División temporal



Linear Regression				
Metric	2019	2020	2021	Mean
MBE	0.08	-1.32	1.10	-0.05
MBEn	0.02	-0.28	0.25	0.00
RMSE	70.49	69.05	70.79	70.11
RMSEn	16.86	14.79	16.37	16.01
MAE	45.08	40.88	44.98	43.65
MAEn	10.78	8.76	10.40	9.98
R ²	0.94	0.95	0.94	0.94

Otras formas de división Train/Test

- Ej: División por sujeto experimental




Table 4. Subject-independent experiments on the LSA64 database. Each column shows the mean accuracy when testing with a subject. The final column shows total mean.


Subject	1	2	3	4	5	6	7	8	9	10	Mean
μ	94.5	93.8	87.7	93.8	91.8	92.6	89.1	90.3	88.4	94.6	91.7
σ	0.66	0.83	1.05	0.79	0.65	0.41	0.91	0.70	0.85	0.66	0.75

Sobreajuste (overfitting)

El Overfitting ocurre cuando el modelo es muy complejo e intenta adecuarse perfectamente a los datos de entrenamiento.

Acc. **Train** alto


Acc **Test** bajo



Modelo con Overfitting

Acc. **Train** alto


Acc **Test** alto



Modelo "correcto"


Acc. **Train** bajo

Acc **Test** no importa




Modelo con UnderFitting

Sobreajuste (overfitting)




Sobreajuste (overfitting)

Curvas de entrenamiento




- Se genera un modelo de datos con Train set
- Se utiliza el mismo modelo con Test Set (Ej. media y desviación).




05

KNN


k-Nearest Neighbors



k-Nearest Neighbors



- KNN (K-Nearest Neighbors) es un algoritmo supervisado que clasifica un dato nuevo según la mayoría de clases entre sus k vecinos más cercanos en el espacio de características.
- No requiere entrenamiento. Almacena datos y calcula distancias (Euclidia, etc.) durante la predicción.
- Es simple y efectivo, pero puede volverse costoso con grandes volúmenes de datos.
- ¡Sensible a la escala de las variables!



k-Nearest Neighbors

- KNN no optimiza parámetros del modelo. (Lazy Learning)
- Cuando se consulta por un nuevo dato, se calculan las distancias.

Nuevo dato	
3	3


feature1	feature2	target
3,09	2,83	A
2,79	2,01	A
0,14	2,58	A
3,43	1,89	A
3,59	4,83	B
4,42	5,12	B
6,67	2,45	B
4,39	4,82	B
1,61	3,60	C
1,43	3,55	C
2,46	4,04	C
3,74	5,20	C
5,99	1,35	D
5,42	1,25	D
3,37	3,68	D
4,42	0,66	D

k-Nearest Neighbors

- Se ordenan las distancias de menor a mayor
- Se toman los K primeros

Nuevo dato	
3	3

feature1	feature2	target	Dist
3,09	2,83	A	0,19
3,37	3,68	D	0,78
2,79	2,01	A	1,01
2,46	4,04	C	1,17
3,43	1,89	A	1,19
1,61	3,60	C	1,52
1,43	3,55	C	1,67
3,59	4,83	B	1,92
4,39	4,82	B	2,29
3,74	5,20	C	2,33
4,42	5,12	B	2,55
4,42	0,66	D	2,74
0,14	2,58	A	2,89
5,42	1,25	D	2,99
5,99	1,35	D	3,42
6,67	2,45	B	3,71







k-Nearest Neighbors

- Se elige la clase mayoritaria

Nuevo dato	
3	3

feature1	feature2	target	Dist	K=5. Conteo	
3,09	2,83	A	0,19	A	3
3,37	3,68	D	0,78	B	0
2,79	2,01	A	1,01	C	1
2,46	4,04	C	1,17	D	1
3,43	1,89	A	1,19		
1,61	3,60	C	1,52		
1,43	3,55	C	1,67		
3,59	4,83	B	1,92		
4,39	4,82	B	2,29		
3,74	5,20	C	2,33		
4,42	5,12	B	2,55		
4,42	0,66	D	2,74		
0,14	2,58	A	2,89		
5,42	1,25	D	2,99		
5,99	1,35	D	3,42		
6,67	2,45	B	3,71		

KNN. Variación de K



Scikit-learn - Ejemplo KNN

```
from sklearn.datasets import load_iris
from sklearn.neighbors import KNeighborsClassifier
from sklearn.metrics import accuracy_score
import pandas as pd

# Cargar el conjunto de datos Iris
iris = load_iris()
X = iris.data # Características
y = iris.target # Etiquetas

# Dividir Tran/test
x_train, x_test, y_train, y_test = train_test_split(X, y, test_size= 0.2)

# Normalizar
scaler = StandardScaler().fit(x_train)
x_train = scaler.transform(x_train)
x_test = scaler.transform(x_test)
```

Scikit-learn - Ejemplo KNN

```
# Crear el clasificador KNN
K=5
modelo= KNeighborsClassifier(n_neighbors=k)

# Entrenar el modelo con todos los datos
modelo.fit(x_train, y_train)

# Realizar predicciones
y_pred_train= modelo.predict(x_train)
y_pred_test = modelo.predict(x_test)

# Calcular la precisión
accuracy_train = accuracy_score(y_train, y_pred_train)
accuracy_test = accuracy_score(y_test, y_pred_test)

# Imprimir la precisión del modelo
print(f"Precisión del modelo KNN en Train para K={K} : {accuracy_train:.2f}")
print(f"Precisión del modelo KNN en Test para K={K} : {accuracy_test:.2f}")
```

RESUMEN

- Aprendizaje Automático y Minería de Datos
- Tipos de problemas y de aprendizaje
- Exploración de Datos
- Preparación de datos
- Evaluación de modelos
- KNN - Sklearn

