

[illegible]

Técnicas de Visualización de Datos

Cómo seleccionar representaciones según los datos y la tarea

Temario

1

Selección de Técnicas

- ✓ Datos
- ✓ Tareas
- ✓ Representación

2

Comparación

- ✓ Barras
- ✓ Puntos
- ✓ Categorías
- ✓ Herramientas

3

Distribuciones

- ✓ Histogramas
- ✓ Boxplots
- ✓ Variabilidad
- ✓ Herramientas


4

Relaciones

- ✓ Dispersión
- ✓ Correlación
- ✓ Patrones
- ✓ Herramientas

De las Decisiones a las Técnicas


- ▶ En la unidad anterior vimos que construir una visualización implica tomar decisiones sobre:
 - ✓ qué **datos** utilizar
 - ✓ qué **tarea** queremos facilitar
 - ✓ qué **marcas y canales** utilizar
 - ✓ cómo organizar la **representación**
- ▶ Existen técnicas de visualización que combinan estas decisiones de formas especialmente útiles para determinadas tareas



DATOS + TAREA → TÉCNICA DE VISUALIZACIÓN

¿Qué Queremos Averiguar?

- ▶ En la unidad anterior vimos que construir una visualización implica tomar decisiones sobre:
 - ✓ **COMPARACIÓN**
¿Cómo difieren los valores entre categorías o elementos?
 - ✓ **DISTRIBUCIÓN**
¿Cómo se distribuyen los valores de un atributo?
 - ✓ **RELACIÓN**
¿Cómo varían conjuntamente dos atributos?
- ▶ La misma colección de datos puede requerir diferentes representaciones según la tarea



Un Dataset para Explorar

Tips

Registros de las cuentas atendidas por un camarero en un restaurante durante aproximadamente dos meses y medio, a comienzos de 1990

total_bill	tip	sex	smoker	day	time	size
16.99	1.01	Female	No	Sun	Dinner	2
10.34	1.66	Male	No	Sun	Dinner	3
21.01	3.50	Male	No	Sun	Dinner	3
23.68	3.31	Male	No	Sun	Dinner	2
24.59	3.61	Female	No	Sun	Dinner	4

El restaurante pertenecía a una cadena nacional estadounidense y estaba ubicado en un centro comercial suburbano. El camarero registró **todas las mesas que atendió durante ese período**, obteniendo 244 observaciones

244 registros · 7 atributos

Cuantitativos: Cuenta · Propina · Comensales

Categoricos: Sexo · Fumador · Día · Momento


Cada fila representa una cuenta registrada en el restaurante.

Descarga directa independientemente de Python: <https://github.com/mwaskom/seaborn-data/blob/master/tips.csv>

Explorando los Datos

Algunas Preguntas:

- ▶ ¿Quién deja más propina: hombres o mujeres?
- ▶ ¿Cómo se distribuyen los montos de las cuentas?
- ▶ ¿La propina aumenta con el monto de la cuenta?
- ▶ ¿Influye el tamaño del grupo?
- ▶ ¿Hay diferencias según el día o el momento?
- ▶ ¿Existen comportamientos inusuales?



*Tenemos 244
cuentas ¿qué
podemos descubrir?*



Comparación

¿Cómo difieren los valores entre categorías o elementos?

- ▶ Comparar permite identificar **diferencias, similitudes y orden** entre valores
- ▶ Podemos comparar:
 - ✓ **elementos individuales**
propina de una cuenta frente a otra
 - ✓ **categorías o grupos**
propinas de hombres frente a mujeres
- ▶ Cuando cada grupo contiene múltiples observaciones, debemos decidir cómo realizar la comparación

¿Quién deja más propina: hombres o mujeres?



Comparación - ¿Qué Significa Dejar Más?

- ▶ Cada grupo contiene **múltiples cuentas y múltiples propinas**
- ▶ Para comparar los grupos necesitamos precisar **qué queremos medir**:
 - ✓ **Propina total**
¿Cuánto dejó acumulado cada grupo?
 - ✓ **Propina promedio**
¿Cuánto dejó en promedio cada cuenta?
 - ✓ **Propina mediana**
¿Cuál es el valor central de las propinas?
- ▶ Cuando cada grupo contiene múltiples observaciones, debemos decidir cómo realizar la comparación

¿Quién deja más propina: hombres o mujeres?



Comparación de Magnitudes

- ▶ Decidimos comparar la **propina promedio por cuenta** entre ambos grupos
- ▶ Para representar una cantidad por categoría podemos utilizar un **gráfico de barras**

GRÁFICO DE BARRAS

- ✓ Cada **barra** representa una categoría
- ✓ Su **longitud** representa un valor cuantitativo
- ✓ Una **escala común** permite comparar las magnitudes



¿Qué grupo presenta una mayor propina promedio?

Propina promedio según sexo

- Eje X: Female / Male
- Eje Y: Propina promedio (\$)
- Dos barras




Repaso

Marca: área rectangular
Canal: longitud/posición
sobre escala común
Categoría: posición en X
Valor: magnitud en Y

La Línea Base Importa

- ▶ En un gráfico de barras, la **longitud de cada barra representa su magnitud**
- ▶ Para comparar correctamente esas longitudes, las barras deben partir de una **línea base común**



Los datos son los mismos ¿la diferencia es grande o pequeña?





En un gráfico de barras, la línea base es parte de la codificación de la magnitud

El Orden Facilita la Comparación

- ▶ Cuando tenemos varias categorías, su **orden puede facilitar o dificultar la comparación**
- ▶ Podemos ordenarlas según:
 - ✓ un **orden propio** de las categorías
 - ✓ la **magnitud del valor** representado

¿En cuál resulta más fácil identificar los extremos y establecer un ranking?



Barras o Puntos

- ▶ Una misma comparación puede construirse utilizando **diferentes marcas y canales visuales**
- ▶ Podemos ordenarlas según:

GRÁFICO DE BARRAS

- ✓ La magnitud se percibe mediante la **longitud** de la barra
- ✓ Las barras parten de una **línea base común**





GRÁFICO DE PUNTOS

- ✓ La magnitud se percibe mediante la **posición** del punto
- ✓ Reduce la cantidad de elementos visuales



¿Necesitamos realmente toda la barra para comparar estos valores?



Barras y puntos ofrecen distintas formas de comparar magnitudes, la elección depende de la tarea


¿Qué Oculta un Valor Resumido?

- ▶ Al comparar grupos mediante un promedio, varias observaciones se resumen en un único valor
- ▶ Ese resumen facilita la comparación, pero puede ocultar diferencias en:
 - ✓ Dispersión
 - ✓ Concentración
 - ✓ Forma
 - ✓ valores extremos

Grupo A: valores muy concentrados alrededor del promedio


Grupo B: valores mucho más dispersos, pero con **el mismo promedio**

Mismo resumen ≠ misma distribución



De las Observaciones a la Distribución

- ▶ Cada cuenta aporta una observación del atributo **total_Bill**
- ▶ Al observarlas conjuntamente podemos empezar a reconocer cómo se reparten sus valores.



¿Cómo podemos ver con mayor claridad dónde se concentran las observaciones?




→ Cada punto representa una cuenta

→ Al observarlas conjuntamente empezamos a reconocer cómo se reparten los valores

Distribución - Agrupar para Ver


- ▶ Podemos dividir el rango de valores en **intervalos**
- ▶ Cada observación se asigna al intervalo que contiene su valor (derivación)
- ▶ Luego contamos **cuántas observaciones** quedan en cada intervalo (agregación)

Un histograma representa la frecuencia de observaciones en intervalos de una variable cuantitativa



Distribución - Los Intervalos Importan

- El número y el ancho de los intervalos determinan **qué valores se agrupan en cada barra**
 - ✓ **Intervalos amplios** resumen más los datos y pueden ocultar diferencias
 - ✓ **Intervalos estrechos** muestran mayor detalle, pero pueden destacar variaciones locales




¿Qué cambia si los datos son los mismos?



La elección de los intervalos condiciona la forma que percibimos

Comparando Distribuciones

- ▶ Un histograma permite observar cómo se distribuyen los valores de un atributo
- ▶ También podemos utilizarlo para **comparar distribuciones entre grupos**



¿Los montos de las cuentas se distribuyen igual todos los días?




Grupos con distinto número de observaciones, ¿Pueden compararse directamente alturas?

Comparando Distribuciones

- Podemos analizar la distribución de un atributo **para diferentes grupos**
- Para compararlas, las representaciones deben utilizar **criterios consistentes**

Utilizar una escala común permite comparar distribuciones



Distribución - ¿Qué Representa la Altura?

- En un histograma, la altura de las barras puede representar diferentes medidas. Para un intervalo i

- ✓ **CANTIDAD**

Número de observaciones en cada intervalo: n_i


- ✓ **PROPORCIÓN**

Fracción de las observaciones que pertenece a cada intervalo: n_i/N

- ✓ **DENSIDAD**

Proporción ajustada por el ancho del intervalo:
 $\text{ancho}_i * n_i/N$

- La forma es la misma, pero cambia el significado de la altura



Distribución – De la Decisión al Código




- ▶ Las decisiones sobre la representación se reflejan en los parámetros utilizados para construir el gráfico
- ▶ En Seaborn, **stat** determina **qué representa la altura de las barras**

```
sns.histplot(  
    data=tips,  
    x="total_bill",  
    bins=10,  
    stat="probability"  
)
```

stat="count"	→ Cantidad
stat="probability"	→ Proporción
stat="density"	→ Densidad

- ▶ La forma es la misma, pero cambia el significado de la altura

Distribución – Una Técnica, varias Herramientas



Matplotlib

```
plt.hist(  
    tips["total_bill"],  
    bins=10,  
    density=True  
)
```

Seaborn


```
sns.histplot(  
    data=tips,  
    x="total_bill",  
    bins=10,  
    stat="density"  
)
```

Plotly

```
px.histogram(  
    tips,  
    x="total_bill",  
    nbins=10,  
    histnorm="probability density"  
)
```

Distribución - Resumir para Comparar

- ▶ Los histogramas permiten observar en detalle la **forma de cada distribución**
- ▶ Comparar varios grupos, analizar simultáneamente todas sus formas puede resultar más difícil



¿Podemos comparar estas distribuciones de una forma más compacta?




- ▶ Podemos utilizar un **resumen de la distribución** que conserve información relevante para la comparación

Distribución - Resumir una Distribución


- ▶ Una distribución puede resumirse con valores que describen su **posición y dispersión**
 - ✓ **MEDIANA:** divide las observaciones en dos mitades
 - ✓ **CUARTILES:** dividen las observaciones ordenadas en cuatro partes
 - ✓ **RANGO INTERCUARTÍLICO (IQR):** distancia entre el primer y tercer cuartil

¿Qué información podemos conservar para describir una distribución?




Distribución - Resumir una Distribución

- ▶ **Boxplot** representa de forma compacta características representativas de una distribución
- ▶ Se construye a partir de la **mediana, los cuartiles y el rango intercuartílico**
- ▶ Boxplot **conserva posición, dispersión y posibles valores atípicos**, pero oculta multimodalidad, huecos o la forma de la distribución



Distribución – Comparar con Boxplot

- ▶ Los boxplots permiten **comparar distribuciones entre grupos** utilizando una misma escala
- ▶ Podemos contrastar rápidamente su **posición, dispersión y valores atípicos**






¿Qué diferencias podemos reconocer entre los días?



El boxplot facilita la comparación, pero muestra menos detalle de la forma de cada distribución

Boxplot – Una Técnica, varias Herramientas



Matplotlib

```
# datos tiene una secuencia  
# de valores por cada grupo  
ax.boxplot(  
    datos,  
    tick_labels=etiquetas  
)
```

Seaborn


```
sns.boxplot(  
    data=tips,  
    x="day",  
    y="total_bill"  
)
```

Plotly

```
px.box(  
    tips,  
    x="day",  
    y="total_bill"  
)
```

Distribución – Observar la Forma


- ▶ Un **violin plot** representa la **forma de una distribución** mediante una estimación de su densidad
- ▶ El **ancho** del violín indica la concentración de observaciones:
 - ✓ Mayor ancho → **mayor densidad**
 - ✓ Menor ancho → **menor densidad**
- ▶ Permite identificar características de la distribución que un resumen oculta



**A mayor ancho
mayor concentración
de observaciones**

Distribución - Comparar la Forma

- Los violin plots permiten comparar tanto el **resumen** como la **forma de las distribuciones** entre grupos




¿Qué diferencias podemos observar entre los días que el boxplot no mostraba claramente?



Distribución – Boxplot vs Violin Plot


boxplot facilita

comparar las medianas,
los IQR, los bigotes y
detectar los outliers






violin facilita percibir

dónde se concentran
los valores y las
similitudes de forma



Violin Plot – Una Técnica, varias Herramientas



Matplotlib

```
# datos tiene una secuencia
# de valores por cada grupo
ax.violinplot(
    datos,
    tick_labels=etiquetas
)
```

Seaborn

```
sns.violinplot(
    data=tips,
    x="day",
    y="total_bill"
)
```

Plotly


```
px.violin(
    tips,
    x="day",
    y="total_bill"
)
```

Distribución - Mismos datos, diferentes representaciones


► Visualizando diferentes tareas para el día sábado




Comparamos un
valor resumido




Recuperamos los
valores individuales



Observamos la forma
de la distribución



Resumimos para
comparar
distribuciones



Estimamos la densidad
para comparar forma
de las distribuciones

► Cada representación conserva información diferente y responde a distintas tareas

Relaciones - ¿Cómo varían conjuntamente dos atributos?

- ▶ Hasta ahora analizamos atributos individualmente o comparamos sus valores entre grupos
- ▶ Ahora queremos observar **dos atributos para cada observación**
- ▶ Buscamos reconocer si existe algún **patrón conjunto** entre sus valores

Cuenta (\$)	Propina (\$)
16,99	1,01
10,34	1,66
21,01	3,50
23,68	3,31
24,59	3,61

¿Las cuentas más altas suelen dejar también propinas más altas?




¿Podemos reconocer la relación observando solamente estos pares de valores?

Relaciones – Dos Atributos, Una Relación

- ▶ Utilizamos **dos atributos simultáneamente** para **analizar la relación: 1 observación → 2 valores**
- ▶ Relacionamos dos valores con la **posición de un punto**
 - ✓ Cuenta → posición horizontal (X)
 - ✓ Propina → posición vertical (Y)
 - ✓ Cada punto representa una observación


Cuenta (\$)	Propina (\$)
16,99	1,01
10,34	1,66
21,01	3,50
23,68	3,31
24,59	3,61

una observación → dos valores → una posición (x, y)



Relaciones – Diagrama de Dispersión

- ▶ Representa la **relación entre dos atributos cuantitativos**
- ▶ Cada observación se representa mediante un **punto**
- ▶ La posición del punto está determinada por dos valores:
 - ✓ Cuenta → posición horizontal (X)
 - ✓ Propina → posición vertical (Y)






¿Qué observamos?

- ✓ **Dirección:**
¿los valores tienden a aumentar o disminuir conjuntamente?
- ✓ **Fuerza:**
¿los puntos siguen un patrón o están dispersos?
- ✓ **Forma:**
¿el patrón parece lineal, curvo u otra estructura?
- ✓ **Casos particulares:**
¿hay puntos alejados del patrón?

Relaciones – Patrones de Relación

- La disposición de los puntos permite identificar diferentes **patrones de relación**




En tips observamos una relación aproximadamente lineal y positiva. ¿Podemos cuantificar qué tan marcada es?



Relaciones – Correlación

- ▶ El **coeficiente de correlación de Pearson (r)** cuantifica la **dirección y fuerza de la relación lineal** entre dos atributos cuantitativos
- ▶ El **coeficiente de correlación r** toma valores entre **-1 y 1** :
 - ✓ $r > 0 \rightarrow$ relación lineal positiva
 - ✓ $r < 0 \rightarrow$ relación lineal negativa
 - ✓ $r \approx 0 \rightarrow$ relación lineal débil o ausente
- ▶ Cuanto más próximo está **$|r|$** a **1** , más fuerte es la relación lineal
- ▶ El coeficiente resume numéricamente parte del patrón que observamos en el gráfico




$R \approx 0.68$

Correlación - Interpretación Visual

► El valor de r refleja la **dirección y fuerza del patrón lineal**


► Signo $\rightarrow$ dirección $|r| \rightarrow$ fuerza de la relación lineal



¿Un valor de r cercano a 0 significa que no existe ninguna relación?

Correlación - No Toda Relación es Lineal

- ▶ El coeficiente de Pearson mide la **relación lineal** entre dos atributos
- ▶ Un valor de **r cercano a 0** indica que no existe una relación lineal marcada
- ▶ Los datos pueden presentar **otros patrones de relación**




El gráfico permite detectar estructuras que un único coeficiente puede ocultar

Correlación - No Toda Relación es Lineal

- ▶ Dos atributos pueden estar **fuertemente correlacionados** sin que uno sea la causa del otro
- ▶ La relación observada puede deberse a:
 - ✓ un **tercer factor** que influye sobre ambos
 - ✓ una relación causal en la **dirección opuesta**
 - ✓ una asociación **casual o espuria**
- ▶ Ejemplo: Si **venta de helados** tiene alta correlación con **personas se bañan en mar**, se puede afirmar que uno implica al otro o viceversa?
- ▶ En realidad, la temperatura es al que influye en ambas
- ▶ La correlación describe cómo varían conjuntamente dos atributos; por sí sola no explica por qué ocurre esa relación




Scatter Plot – Una Técnica, varias Herramientas




Matplotlib

```
plt.scatter(  
    tips["total_bill"],  
    tips["tip"]  
)
```



Seaborn

```
sns.scatterplot(  
    data=tips,  
    x="total_bill",  
    y="tip"  
)
```



Plotly

```
px.scatter(  
    tips,  
    x="total_bill",  
    y="tip"  
)
```

Técnicas de Visualización — ¿Qué queremos observar?

► COMPARACIÓN

¿Cómo se comparan los valores entre categorías o grupos?

Barras · Puntos →

Facilitan comparar **magnitudes y posiciones**

► DISTRIBUCIÓN

¿Cómo se distribuyen los valores de un atributo?

Observaciones · Histograma · Boxplot · Violin plot →

Permiten observar **frecuencia, dispersión, forma y valores atípicos**

► RELACIONES

¿Cómo varían conjuntamente dos atributos?

Diagrama de dispersión · Correlación →

Permiten reconocer **dirección, fuerza, forma y casos particulares**

La elección de una representación depende de la tarea y de qué características de los datos necesitamos hacer visibles

