


Práctica 5

Visualización de Datos Multidimensionales



Objetivos

- ✓ Analizar datos multidimensionales, identificando atributos y relaciones relevantes para una tarea.
- ✓ Explorar relaciones entre múltiples atributos mediante representaciones que permitan comparar pares de dimensiones.
- ✓ Construir y evaluar representaciones multidimensionales, considerando posibilidades y limitaciones.
- ✓ Aplicar técnicas de reducción dimensional para obtener representaciones de datos de alta dimensión.
- ✓ Interpretar y comparar representaciones, justificando las decisiones de mapeo y transformación.

Temas

- ✓ Datos multidimensionales y relaciones entre atributos.
- ✓ Matrices de dispersión y correlaciones.
- ✓ Coordenadas paralelas, perfiles multidimensionales y gráficos de radar.
- ✓ Reducción dimensional: PCA, t-SNE y alternativas.

Lectura

Munzner, T. (2014). *Visualization Analysis & Design*. CRC Press. Capítulos 7, 8 y 14.

Ejercicio 1

Utilice el dataset **penguins** y considere los siguientes atributos:

bill_length_mm, **bill_depth_mm**, **body_mass_g**, **species** y **sex**

- a) Construya un diagrama de dispersión que represente:

- **bill_length_mm** → posición X
- **bill_depth_mm** → posición Y

Analice la representación. ¿Puede identificar grupos o patrones en los datos? ¿Qué información de cada pingüino queda representada?

- b) Incorpore **species** utilizando **color**.

Compare esta representación con la anterior. ¿Qué patrón se hace ahora más evidente? ¿El color resulta un canal adecuado para representar este atributo? Justifique considerando su **expresividad y efectividad**.

- c) Incorpore además **body_mass_g** utilizando **tamaño**.

Analice qué información adicional puede obtenerse. ¿Resulta sencillo comparar la masa corporal de los pingüinos? ¿El nuevo canal facilita o dificulta alguna de las tareas anteriores?

- d) Incorpore **sex** utilizando **forma**.

Analice la representación resultante considerando simultáneamente los cinco atributos. ¿Qué relaciones o patrones puede reconocer? ¿Cuáles resultan difíciles de observar?

- e) Compare las cuatro representaciones obtenidas. Para la tarea de **identificar diferencias entre especies**, determine qué atributos y canales mantendría en la visualización y cuáles eliminaría. Justifique su elección.

Ejercicio 2

Utilice el dataset **penguins** y considere los cuatro atributos cuantitativos:

bill_length_mm, **bill_depth_mm**, **flipper_length_mm** y **body_mass_g**.

- a) Construya una **matriz de diagramas de dispersión (pairplot)** para los cuatro atributos, utilizando **species** como color.

Analice la matriz e identifique:

- dos atributos que presenten una relación positiva.
- dos atributos que presenten una relación negativa.
- el par de atributos que considere más útil para diferenciar visualmente las especies.

Justifique sus respuestas a partir de lo observado.

- b) Calcule la **matriz de correlación** de los cuatro atributos cuantitativos y represéntela mediante un **mapa de calor**, utilizando una escala divergente centrada en cero.

Identifique el par con mayor correlación positiva y el par con mayor correlación negativa. Compare estos resultados con lo observado en el apartado anterior.

- c) Seleccione uno de los pares con correlación alta en valor absoluto y vuelva a observar su **scatterplot**. ¿La correlación resume adecuadamente lo que muestra la representación? ¿Qué información presente en el **scatterplot** se pierde al reducir la relación a un único valor?

Ejercicio 3

Utilice los cuatro atributos cuantitativos de **penguins**.

- Normalice los atributos y construya un gráfico de **coordenadas paralelas**, utilizando **species** como color.
- A partir del gráfico, describa las principales diferencias que observa entre los perfiles de las tres especies.
- Modifique el **orden de los ejes** para facilitar el análisis de las relaciones entre atributos. Compare ambas representaciones. ¿Qué relaciones se hacen más evidentes?
- Experimente con la transparencia de las líneas. ¿Cómo afecta la posibilidad de reconocer grupos y patrones?
- Indique dos ventajas y dos limitaciones de las coordenadas paralelas para analizar este conjunto de datos.

Ejercicio 4

Utilice los cuatro atributos cuantitativos de **penguins**.

- Calcule el **valor promedio de cada atributo por especie** y normalice los resultados.
- Construya un **gráfico de radar** con un perfil para cada especie.
- Analice los perfiles. ¿Qué atributos permiten diferenciar mejor las especies? ¿En cuáles presentan comportamientos similares?
- Compare el radar con las **coordenadas paralelas** del ejercicio anterior. ¿Qué información facilita observar cada representación?
- Modifique el orden de los atributos en el radar. ¿Cambia la percepción de los perfiles aunque los datos sean los mismos? Explique.

Ejercicio 5

Utilice los cuatro atributos cuantitativos de **penguins**.

- Estandarice los atributos y aplique **PCA** para reducir los datos a dos dimensiones.
- Represente PC1 y PC2 en un scatterplot, utilizando **species** como color. Indique qué porcentaje de la variabilidad explican conjuntamente ambas componentes.
- Analice qué atributos tienen mayor influencia sobre cada componente principal.
- Aplique **t-SNE** sobre los mismos datos y represente el resultado en dos dimensiones. Compare los grupos obtenidos con PCA.
- Compare PCA y t-SNE. ¿Qué información permite interpretar cada técnica y qué precauciones tendría al analizar sus representaciones?